

一個以差分進化演算法為基礎之
車輛異常行為檢測系統
**A Misbehavior Detection System Based on
Differential Evolution Algorithm**

國立中山大學資訊工程學系
111 學年度大學部專題製作競賽

組員：B083040020 童冉琳
B083040031 邱歆惠
B083040045 李亦晴

指導教師：蔡崇煒 教授

(團隊貢獻表)

團隊成員貢獻說明

專題名稱(中文): 一個以差分進化演算法為基礎之車輛異常行為檢測系統

專題名稱(英文): A Misbehavior Detection System Based on Differential Evolution Algorithm

※ 請詳述團隊分工情形：

| | 個人完成內容 | 貢獻比例 | 組員簽名 |
|----|-------------|------|------|
| 1. | 方法程式撰寫、論文撰寫 | 40% | 李亦晴 |
| 2. | 方法程式撰寫、模型測試 | 40% | 邱歆恩 |
| 3. | 方法程式撰寫、模型測試 | 20% | 董冉琳 |
| 4. | | | |
| 5. | | | |

※ 本作品若以其他原著作品為基礎，經大幅度修正或改進者，請詳述本作品與原著作品之關連性及不同之處：

本作品以原車輛異常行為檢測系為基礎進行辨識準確度改良，利用差分進化演算法以策略性搜索最佳解的特性，尋找對各異常行為辨識系統最適超參數，並且以單個異常行為模式為啟發，增加辨識特徵。從以上兩層面著手改進車輛異常行為檢測系統的辨識能力。

註：如不敷填寫，可另以附件呈現。

指導教授簽名：蔡崇煒

日期： 年 月 日

摘要

車載隨意行動網路 (vehicular ad-hoc network; VANET) 以無線網路通訊的特性，打造車輛間能夠互通有無的聯絡網，成為能廣泛應用於道路上的對象。在利用其便利性的同時，網路系統通常蒙受故障、遭入侵等等風險中，VANET 也不例外，需要高度準確的車輛異常行為檢測系統 (misbehavior detection system; MDS) 為行車安全把關。現有的 MDS 多使用人工測試調整參數，在效率上稍顯不足。本研究嘗試以超參數自動最佳化的方式提升 MDS 偵測準確度，並選擇採用差分進化演算法 (differential evolution; DE) 以具策略性的猜測，更有效率地找尋近似的最佳解，為不同的異常行為分類器賦予最適超參數。研究中也由異常行為模式進行發想，為 MDS 增添新特徵，以提高辨識異常行為的能力。本研究的模型訓練以及評估模型效能皆採用 VeReMi Extension 資料集，研究將分成三個實驗驗證提出方法之成效，實驗結果表明與未經超參數最佳化的原異常行為檢測系統相比，系統在辨識異常行為上包括準確度 (Accuracy)、精確度 (Precision)、召回率 (Recall)、F1-score 皆有提升，最終各項異常行為辨識準確率達 97.6%，驗證本研究提出之作法能夠確實提高 MDS 的判斷能力。

目錄

| | | |
|----------|----------------------------|-----------|
| 1 | 簡介 | 3 |
| 2 | 文獻探討 | 6 |
| 2.1 | 資料集 | 6 |
| 2.2 | 入侵偵測系統 | 7 |
| 2.3 | 超參數最佳化 | 8 |
| 3 | 研究方法 | 10 |
| 3.1 | 以 DE 實作 HPO 各項程序 | 12 |
| 3.2 | 特徵 | 15 |
| 4 | 結果與討論 | 17 |
| 4.1 | 資料集與 MDS 重建 | 17 |
| 4.2 | 實驗設定與分析 | 20 |
| 5 | 結論與未來工作 | 26 |
| 6 | 致謝 | 27 |
| 7 | 參考文獻 | 28 |

1 簡介

WHO 提出的道路安全報告 [1] 中統計，2016 年交通事故在青少兒致死因素中高達第一名，並且在全年齡的死亡率存在逐步成長的趨勢，預估隨著醫藥技術不斷進步的同時，交通事故的傷亡將會超越不少疾病，竄升至更高名次。不僅止於個人生理上的危害，交通事故對於國家也產生相當高的經濟代價，據報告 [2] 的統計資料表明，每年先進國家因交通事故約損耗 GDP 的 2~5%，其中包括社會與經濟成本上的損失，可見交通事故對各方的危害之巨大。

智慧交通系統 (intelligent traffic system; ITS) [3] 可以輔助緩解此一現況，利用搭載於車輛及道路的感測器 (sensor) 探測個別車輛與道路資訊的數據，以物聯網 (internet of things; IoT) 技術，為車輛對車輛 (vehicle-to-vehicle; V2V) 和車輛對基礎設施 (vehicle-to-infrastructure; V2I) 之間創造相互溝通的 VANET 聯絡網，建立更完整的交通實時狀況圖譜，並使用雲端計算 (cloud computing)、巨量資料分析 (big data analysis) 與人工智慧 (artificial intelligence; AI) 技術將蒐集的數據妥善分析預測，以做出相應決策管理交通，及時調節道路狀況，使城市兼具安全性及舒適性，減少壅塞也提升運輸效率，並且也是自動駕駛得以實現的重要一環。ITS 在交通上應用性相當廣泛，包括交通號誌智慧控制、及時車流及交通擁堵偵測、最優路線尋找、泊車輔助系統等，在智慧交通號誌控制方面，主要聚焦於尋找最佳的號誌控制策略以最小化整體車輛的行駛時間，透過考慮預估車輛抵達路口時間、最大化通過號誌車輛數等因素、以最佳化演算法找尋當前適宜號誌週期、燈號時間，近年更增加燃料消耗、廢氣排放的評估，在達減少停等時間目的的同時，也響應環保趨勢；而在即時車流偵測的方法更是多元，可以透過像是超音波、雷達等感測器感測車流、以影像辨識車輛密度，也能透過車輛架設的車載單元 (on board unit; OBU) 在每個節點間週期性廣播，或是由移動車輛及靜態路側傳感器即路側單元 (road

side unit; RSU) 的互動決定當前車流狀態，交流的資訊也提供智慧交通更多分析應用，衍生出偵測危險行為、預測事故好發路段的功能。

這些功能能夠擴大並增強駕駛對於環境的感知力，使人、車、路有更充分的溝通。相關判斷分析多奠基於資料的正確性上，然而資料正確性可能在資料蒐集環節遭遇傳感器故障，或是在 VANETs 傳輸環節遭受網路攻擊，影響智慧交通系統的運作，進而威脅到駕駛及道路安全。傳感器故障包括像是常數位置偏移 (constant position offset)，用於定位的感測器所感測到的位置，與車輛所在的正確位置存在極大誤差，相似的故障行為也可能體現於速度感測器，或是感測器感測資料固然正常，在傳輸上卻具較高延遲性導致接收端收到的資訊與真實資料相異；攻擊則包括常見的女巫攻擊 (sybil attack) [4]，透過冒充成真實存在的節點擾亂網路運行，在 VANET 中可造成稱作 traffic congestion sybil 的攻擊，以大量的冒充節點製造交通擁堵的假象，使智慧系統判斷錯誤造成交通紊亂。本文中提及的車輛異常行為即是這些 VANET 中可能的故障和攻擊的統一稱呼，儼然對於智慧交通的運行造成危害，所以這些在 VANET 流通供以判斷的訊息需要車輛異常行為檢測系統為其把關，檢測不當行為確保行路安全。

上述提供 V2V、V2I 在 VANETs 中相互通傳、提供用以判斷的訊息具有統一格式，即由 SAE J2735 [5] 標準定義的基本安全訊息 (basic safety message; BSM)，BSM 的內容包括車輛的座標位置、速度、加速度、傳送者、傳送時間等，也是 MDS 檢測車輛異常行為的依據。在智慧交通的運行中，BSM 以標準建議的 10 毫秒為間隔進行週期性低延遲傳輸，以 V2V 模式收到附近車輛的 BSM，即可由 OBU 中的 MDS 進行車輛異常行為檢測。若受檢車輛檢出具異常行為，OBU 則以 V2I 模式向最近的 RSU 標記該受檢車輛，以利後續對於對其進行處置。此外若車輛進出不同 RSU 的區域範圍，OBU 也會由 RSU 載下該區域定期更新訓練的 MDS 模型，以應變道路上千變而層出不窮的新事件。隨智慧交通的推進以及安全意識抬頭的趨勢下，對於 MDS 已有許多相關

研究，然涉及安全性問題應更嚴謹看待，使系統判斷盡量臻至精確完善。提升車輛異常行為的辨別能力有許多方法，模型超參數最佳化是本文主要聚焦研究的議題，透過找尋最適合模型的超參數達到提升判斷準確度的目的。現今機器學習系統多以手動調整、人工測試超參數組合，不僅耗費人力且最佳化效率不高，尤其 MDS 的應用要適應各地區並應時更新，具備因時因地制宜的特性，若仍仰賴人工測試可想其工作量之龐大，實非明智之舉。自動化機器學習 (automated machine learning; AutoML) [6] 的概念可利用於超參數最佳化 (hyperparameter optimization; HPO)，以機器學習取代手動測試，自動嘗試尋找最適宜的超參數設置，達到更有效率提升模型性能的目標。本研究為考量 MDS 訓練時間成本，選擇使用屬於超啟發式演算法的差分進化演算法作為自動最佳化方法，以具策略性方式在合理成本下搜索最佳解。本文主要貢獻包括：

- (1) 以引入以 DE 演算法自動的為 MDS 實施超參數最佳化，提高模型檢測的準確度。
- (2) 比較研究中使用的方法在不同分類器功效差異。
- (3) 新增以 EventualStop 異常行為模式啟發的特徵，使系統對於個別異常行為的判斷能力提升。

本文的各章節發展脈絡，包括先於第二章節分別回顧 VANET 中對於異常行為檢測的系統與資料集發展、並探討超參數最佳化流程與各種不同最佳化方法間差異。主要方法則於第三章節進行說明，介紹整體架構以及超參數最佳化的實作，第四章節針對提出的方法設計三項實驗並進行成果評估分析與討論，最後於第五章節為本研究作統整。

2 文獻探討

2.1 資料集

MDS 研究發展早期所使用的資料集，通常需要由研究人員據其需求自行生成，或是以模擬軟體測試評估該研究方法在 VANET 中的效能。像是 Belenko 等人 [7] 考量因真正的 VANET 架設成本過高而使相關領域缺乏資料集，然而研究及開發人員卻需要相關資料以更了解車際網路之間的行為，所以採用網路模擬器 NS-3 對於真實環境、道路場景進行模型建構，成功模擬 VANET 環境。但模擬工具的使用具複雜步驟以及相對高昂的計算成本的問題，並且領域中缺乏大型共通的資料集提供評估基準，也會導致不同的檢測機制間難以相互評比，較不利於研究的發展。直到 Heijden 等人在研究 [8] 中提出了開源資料集 Vehicular Reference Misbehavior Dataset (VeReMi)，甫解決此一問題。VeReMi 資料集是在以交通模擬軟體建立的盧森堡交通場景 (Luxembourg SUMO traffic; LuST) [9] 中，利用混和模擬框架 (vehicles in network simulation; VEINS) [10] 模仿車輛在 VANET 中的行為所生成的資料集，生成內容包含目標車輛所接收到來自所有附近車輛的 BSM 與 GPS 訊息，相較於模擬工具，VeReMi 資料集既簡單易使用，又無模擬工具高額計算成本的缺陷，可說是為研究領域創造良好的比較標準，為 MDS 應用於 VANET 的發展邁出關鍵一步。後續有不少研究以 VeReMi 資料集為基礎進行增加及改良，Kamel [11] 提出的 VeReMi Extension 資料集便是其中之一，他修正原先版本在異常行為 EventualStop 種類中，較不合理的標記時機，也與時俱進的新增數種異常行為種類，並且基於真實情境中感測器可能出現誤差的考量，在模擬中增加誤差模型，模仿實際情境中感測器在探測上可能出現的位置、速度、加速度以及方向上的誤差，更大幅增進資料集的真實性。

2.2 入侵偵測系統

在 VANET 環境中，為避免因故障或遭攻擊的車輛不斷傳送錯誤訊息，進而擾亂智慧運輸系統的運作，車載異常行為檢測系統的相關研究應需求而生。隨著機器學習領域的崛起，開發及研究人員也將技術導入入侵偵測系統中，幫助更傑出的判斷檢測異常行為。Grover 等人 [12] 提出的方法就是其中之一，他們運用集成學習方法，組合多種機器學習的模型作為判別系統，分辨由 NCTUns-5.0 模擬器 [13] 模擬在不同場景中架設的 VANET 環境，可能具備的車輛行為特徵，在成功分辨多數異常行為的同時，也獲取比單一機器學習模型更優秀的辨別成果。而車載異常行為檢測系統研究領域的進程，也在 VeReMi 資料集的發表下迎來長足的發展，像是 So 等人 [14] 便針對 VeReMi 資料集中有關位置異常的行為，在提出的系統框架中增加對於位置的合理性檢查特徵向量，並將其輸入支持向量機 (support vector machine; SVM) 與 K -近鄰演算法 (K -nearest neighbors; KNN) 模型分判異常，實驗結果表明加入合理性檢查能夠將整體判斷精確度 (Precision) 提升 20% 以上，並且一旦檢測到異常行為，即將其分類到不同類型的已知異常行為種類，更有利於針對異常行為採取更具體且精準的行動加以抑制。

針對 VANET 的入侵偵測系統的研究不僅運用機器學習相關技術，隨著研究的推進也嘗試深度學習演算法提升研究成果。像是 Tejasvi [15] 等人發表的論文當中，利用卷積神經網路 (convolutional neural network; CNN) 具優秀的特徵擷取能力的特性，結合改良 Harsh 等人 [16] 單純以堆疊式長短期記憶 (long short-term memory; LSTM) 的位置重構模型，模型為了學習車輛正常行為模式以成功重構位置，全面採用正常行為序列數據進行訓練，若將異常行為序列輸入習得正常模式的重構模型中，模型所預測重構的位置序列將會與原序列產生較大的偏差，最後將此差值以基於閾值的分類演算法計算分界，當差值超過界定範圍則判定為異常行為。研究中也驗證以 CNN-LSTM 作為重構模型結合閾值分類演算法，比堆疊式的 LSTM 具備更優秀的性能。誠然重構階段

為後續對於異常的判斷增加不少判斷依據，但重構僅考慮少數車輛運動訊息，並且採用閾值過分簡單的為正常及異常作分界、缺乏更多面向的檢查。Cheng 等人基於以上考量，對 [15] 提出的方法進行改善，延續使用 CNN-LSTM 作為位置重構模型，但以 [14] 當中使用的 SVM 分類器取代閾值分類演算法，並且每個 SVM 分類器皆增加參考包括位置重構的偏差以及合理性檢查 [14] 在內的 11 項特徵，也證實此檢測系統相較 [14] [15] 對異常行為具有更傑出的分辨能力。

2.3 超參數最佳化

在機器學習、深度學習等技術應用至各領域的同時，模型也必須快速適應不同的使用情境，人工測試及調整參數的工作量隨之日漸龐大，自動超參數最佳化 (hyperparameter optimization; HPO) 的重要性即從中體現，透過自動嘗試為模型設定適宜的超參數組合，除了降低人力資源耗費並能直觀的提升模型整體性能，也藉由將不同的模型以 HPO 施以契合的超參數，使其能不因設置不當問題影響，能夠更大程度站在相同起跑線，使以不同演算法建構的模型間更具有比較性，幫助研究人員釐清對於特定問題領域適合使用的演算法模型。實現超參數最佳化的主要流程如下 [17]:

- (1) 選定實施超參數最佳化的目標模型，並針對目標情境設定用以評估模型性能的指標。常見的評估指標包括均方根誤差 (root-mean-square error; RMSE)、準確度等。
- (2) 針對目標模型總結適用調整的超參數，據其特性選擇適宜的最佳化方式。
- (3) 以預設的超參數設定或是該演算法模型的常用數值作為基準，用以訓練模型作為對照。
- (4) 透過人工測試或對於問題領域既有的認知，縮小搜索空間並鎖定可行解範圍以開始 HPO 過程。
- (5) 根據迭代測試性能較優良的超參數值不斷收攏搜索範圍，或是在必要時探

索新空間。

(6) 當滿足終止條件時，返回當前最佳組合作為模型最終超參數配置。

超參數最佳化的方法攸關模型最佳化效率及成效，選定適宜的最佳化方式可以說是流程中相當重要的環節。在 Li 等人 [18] 針對 HPO 應用於機器學習領域的統整性研究中，說明許多 HPO 問題屬於非凸函數，或是具有不可微分特性，使傳統最佳化演算法諸梯度下降等的使用受限。其他常見用於實作超參數最佳化的演算法則在不同情境中各有其優劣之處，像是網格搜索 (grid search; GS) [19] 與隨機搜索 (random search; RS) [20] 兩項慣用於超參數最佳化的方法，已有許多研究證實在足夠的時間花費下，能夠找到全局最佳解或近似最佳解，但每次的搜索及嘗試都是相互獨立、並不承襲以往經驗，導致耗費龐大的時間成本在搜索與評估表現差勁的區域、較欠缺效率，所以多只在搜索域較小的問題上具有較佳的表現。貝葉斯最佳化 (Bayesian optimization; BO) [21] 的方法則會考量過去的測試結果，不斷修改未來評估點，逐步調向表現優良區域，也使效率上較 GS 與 RS 突出，然而對於不同類型的 HPO 問題，在不同的代理模型的選擇上具有限制。啟發式演算法 [22] 對於許多 HPO 方法相對複雜，但卻也是應用性最廣泛的方法之一，能夠應對幾乎所有類型的 HPO 問題，尤其適合複雜的最佳化以及面對較大的搜索空間的問題，透過有策略性地搜索模式，相對其他方法能夠更有效率的找尋近似的全域最佳解。Schmidt 等人 [23] 的研究討論並主要針對貝葉斯最佳化演算法與啟發式演算法進行比較，測試前者基於序列模型的演算法架構 (sequential model-based algorithm configuration; SMAC) 與屬於後者範疇的差分進化演算法 (differential evolution; DE) 兩種方法在 HPO 上的性能，以 SMAC 及 DE 對包含隨機森林、KNN、SVM 在內的六種機器學習分類器實施超參數最佳化，使分類器能夠分別在 49 種不同資料集的情境中，找到最適合當前問題的模型超參數設置。在 49 個項目的評估中，較多數以 DE 進行 HPO 分類器成效較佳，也印證 DE 在超參數最佳化的性能在更多情況表現優於 SMAC，具備更優秀的廣泛應用性。

3 研究方法

本研究將針對研究 [24] 提出的車載網路異常行為檢測系統進行重建，並對其實施超參數最佳化。由於 Cheng 等人版本的系統中，對於以不同種類的車輛異常行為資料訓練的分類器，皆使用相同數值的超參數組合，可能因運用較不適配的超參數值，導致個別異常行為分類器無法達到最佳的判別成效。基於以上考量，本研究主要針對不同異常行為分類器的訓練期間，採用 DE 作為最佳化演算法實行 HPO，由替個別異常行為分類器設定最適合的超參數組合著手，使系統能夠更大程度發揮其效能。DE 屬於一種啟發式演算法，不僅不似梯度下降等演算法囿於可微分問題，也能透過具策略性的方法有效率的在大範圍進行搜索，減少在相對無效區域中測試訓練的龐大時間成本，並且在 HPO 問題上也受 Schmidt 等人 [23] 於論文中證實具有更優異表現。

DE 演算法源於生物進化的概念，模仿生物種群中的繁衍模式，藉由種群中突變個體為種群帶來多樣性並不斷透過交配繁殖子帶，利用對於環境適應值的評價以優勝劣汰決定種群演進方向。突變階段的實現參考種群中隨機的個體向量差做為突變的影響因子，以不同突變策略對目標向量進行改變以形成突變向量，再透過交配的方式將突變向量與原本的目標向量相互組合產生子代，最後透過評斷子代與父代的優劣，淘汰適應值表現較差者，並將適應值較佳者留作新一帶的目標向量，多次重複上述步驟以達到趨近全局最佳解的可能性。圖1是本研究針對 [24] 系統之 SVM 分類器建構的 HPO 架構，主要流程包含初始化、突變、交配與選擇，並判別是否終止。不同向量指代的是不同的超參數組合，並且因本研究主要針對的是 MDS 進行最佳化以提升判斷準確度，所以個體適應值的評估是採用模型準確度作為評斷標準，具體透過交叉驗證分割訓練集得到多次準確度成果，並對其取平均值而來。終止條件則是指產生的世代若達到設定的迭代數，或者連續多次迭代皆保持相同的適應值，達到預設所耗時間成本，或是評估沒有發展性時便結束最佳化，最終

的目標向量即為差分進化演算法進行 HPO 為 SVM 分類器找尋的最佳超參數組合。此外 DE 也不免面臨多數最佳化演算法落入區域最佳解的問題，本研究也透過動態的改變當中的權重值，減緩過早收斂的缺陷。除了透過 DE 執行車輛異常行為檢測系統之分類器的超參數最佳化，提升對於異常行為的判斷能力，本研究另外也由部分準確率相對較差的異常行為類別著手，以行為模式特性建立針對性的檢測特徵，提高系統整體對於是否為異常的判斷準確度。

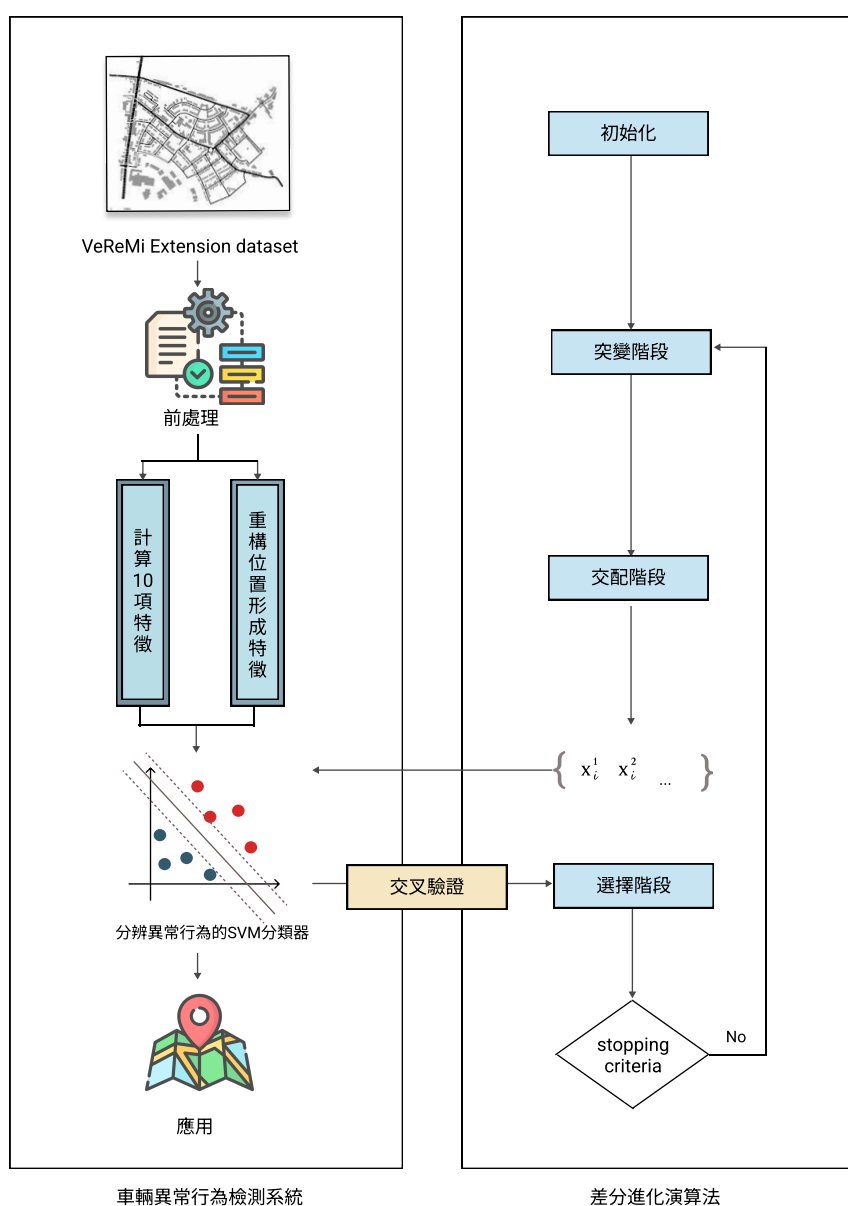


圖 1: 本研究以差分進化演算法針對 MDS 系統實施 HPO 之架構

3.1 以 DE 實作 HPO 各項程序

本節將針對圖1之 HPO 流程進行細部的解釋，又因原系統以 SVM 分類器進行是否為異常的分辨，本節主要也以 SVM 的相關設定為例輔助說明 HPO 具體實施流程。表1為 SVM 在使用不同的 kernel 下能夠有效控制調整的超參數。鑑於不同 kernel 間對於同名的超參數具不同的運算及應用，在 RBF kernel 中表現優秀的數據不見得在 poly 中具同樣表現，較不適合相互繼用運算，並且在研究初期的測試當中，RBF 在整體效能表現上優於其他 kernel，本研究對於 SVM 的 HPO 上主要針對 RBF kernel 下的 C 及 γ 進行調整以達最佳化目的。

表 1: SVM 分類器可調整之超參數

| kernel | hyperparameter |
|---------|--------------------------------|
| RBF | C , γ |
| poly | C , γ , degree, coef0 |
| sigmoid | C , γ , coef0 |

C 代表的意義是懲罰係數，主要透過控制對於誤差的容許度、決定離群點的影響力，用以平衡分類器的分類精度和模型複雜度，懲罰係數 C 愈大表示愈不允許節點被分到錯誤類別，代表即使是較遠的離群點也會被劃入考量範圍，為使其分類正確，會造成支持向量增多、模型也隨之複雜，若是考量太多離群點而將其過度設定，會造成模型過度契合訓練集的過擬合的問題。 γ 代表的則是核函數參數，支配的是每個單一支持向量能夠作用的範圍， γ 值設定與能夠作用的範圍存在倒數關係， γ 越小會使單一支持向量的影響範圍越大，若設定太小致使單一支持向量作用範圍太大，顯然導致模型對於較複雜、精緻細小的部分難以處理。綜合 C 及 γ 特性，本研究透過調整兩項係數的組合，使模型能夠在精確度與複雜度間取得適當平衡，在達判斷正確的目的同時，模型也能夠具有較佳的效能。

A. 初始化

初始化步驟的實現方法，透過隨機選擇 $n_{\|p\|}$ 組超參數的數值作為初始種群，每個個體向量記作 x_i ，由選定調節的目標超參數編碼組成，可由以下公式呈現：

$$x_i = (x_i^1, x_i^2, \dots, x_i^d). \quad (1)$$

雖後續研究將嘗試以不同分類器進行，本文此處主要以 SVM 舉例，調整懲罰係數 C 及核函數參數 γ ，由此可知此處維度設定 $d = 2$ ，且式1中 x_i^1 指代的是 C 、 x_i^2 指代的則是 γ 。為了使初始種群能夠均勻散佈於搜索範圍，有利更充分探索全域可行解、減少遺漏嘗試最佳解範圍的可能性，在初始化期間，個體會由隨機方式在各維度設定的範圍內生成，此範圍通常由人為測試或是專家學者對於該領域的既定認知訂制。向量初始化的公式如下：

$$x_{i,0}^j = x_{\min}^j + \text{rand}(0, 1) \times (x_{\max}^j - x_{\min}^j), \quad (2)$$

公式中 x_{\max}^j 及 x_{\min}^j 分別為第 j 維度當中設定的上下界， $x_{i,0}^j$ 表示在初始的第 0 代時第 i 個體於第 j 維度超參數的值，其中 $i = \{1, 2, \dots, n_{\|p\|}\}$ 。

B. 突變

在此階段會透過差分突變形成突變向量 $v_{i,t+1}$ ，DE 的相關研究在突變上由核心的差分，變異出不少突變策略，核心觀念大抵都是在種群中隨機挑選向量，以計算的向量差為基準，並搭配突變權重 F 進行調整以產生突變向量。本研究使用的突變策略是 DE/rand-to-best/1，此策略的特性會考慮隨機因素及當前的種群最佳解，在向最佳解方向靠攏的同時，也增加隨機因素保持探索性、防止過早收斂。DE/rand-to-best/1 公式表示如下：

$$v_{i,t+1} = x_{r1,t} + (x_{\text{best},t} - x_{r3,t}) + F \times (x_{r1,t} - x_{r2,t}) \quad (3)$$

$r1, r2, r3 \in \{1, 2, \dots, n_{\|p\|}\}$ ，且 $r1 \neq r2 \neq r3$ ， t 所表示的是當前迭代次數。其中控制參數 F 具備以下特性，若設定過大會使隨機因素影響較大，導致不

易收斂；倘若設定過小則可能致使過早開始收斂，落入區域最佳解。而對於最佳解的搜索，通常期望在迭代搜索前期適度保有多樣性，在後期則期待減少隨機性達加速收斂的效果，本研究基於以上性質，對於突變權重 F 的設定加入動態因素，以模擬退火演算法 (simulation annealing; SA) 的降溫機制使其能夠隨迭代動態調整，達到在探索初期保持隨機探索性、在後期加速收斂的目的。

C. 交配

此階段透過目標向量 $x_{i,t}$ 與突變向量 $v_{i,t+1}$ 當中數值的隨機抽調，模擬物種交配基因交融產生子代的過程，此步驟產生的子代 $u_{i,t+1}$ 又稱試驗向量，具體的交配方式如下公式所示：

$$u_{i,t+1}^j = \begin{cases} v_{i,t+1}^j & \text{if } \text{rand}_{j[0,1)} \leq c_r \text{ or } j = j_{\text{rand}}, \\ x_{i,t}^j & \text{other.} \end{cases} \quad (4)$$

雜交概率 c_r 是此步驟關鍵的控制參數，倘若生成隨機值小於 c_r ，子代在當前維度的值會採用突變向量之值，反之則保留原目標向量在該維度的超參數數值。此外為了確保子代和父代的差異性，以利最佳化探索，試驗向量必定會有一個維度以上的數值和原目標向量相異，透過隨機方式挑選一個維度 j_{rand} ，則 j_{rand} 所指代的超參數將會不受 c_r 的影響必定接受突變向量產生的新值。

D. 選擇

在選擇階段則需要評估試驗向量與目標向量的適應值，選擇表現較佳者做為下一次迭代的目標向量。對於本研究而言的使用情境是判斷是否為異常行為，所以適應值在研究中所代表的意義是對於異常行為判斷的準確度，選用 k 折交叉驗證將訓練集分作 k 組，每次選取 $k - 1$ 組作為本次驗證的訓練集，剩餘的一個組別則作為測試集驗證該模型的準確度，執行 k 次後取平均值作為

評估模型適應值優劣的標準，可以表示成以下公式：

$$x_{i,t+1} = \begin{cases} u_{i,t+1} & \text{if } f(u_{i,t+1}) \geq f(x_{i,t}), \\ x_{i,t} & \text{other.} \end{cases} \quad (5)$$

其中 $f()$ 表示 k 折交叉驗證結果的平均值計算函式。輸入試驗向量或目標向量數值，以該超參數組合訓練模型，並輸出進行 k 次驗證的準確度平均值作為選擇階段的評價標準，以利對不同超參數組合進行比較。

在選擇階段過後即判斷是否達到終止條件，若否則回歸突變步驟開啟新一輪的迭代，不斷產生新的超參數組合，直到達到完成最大迭代數，或是連續 10 代維持相同目標向量，以耗光預設的時間成本，或是評估是否具有發展性作為結束基準，終止循環後會輸出當前的目標向量作為最佳解，成為該車輛異常行為檢測系統中分類器的最佳超參數組合。

3.2 特徵

本研究除了使用 DE 對分類器實施超參數最佳化提升模型效能，為了提升部分仍較難以分別的異常行為的分辨率，另外也新增了可以針對個別異常行為進行檢測的新特徵。像是其中一種異常行為類別 EventualStop，這種異常行為類別具體運作模式為突然將原先正常行動的車輛位置凍結，然而在速度資訊上卻顯示仍然在進行移動，模擬車輛突發異常靜止的攻擊型態，根據以上 EventualStop 定義的異常行為模式可以以下公式闡述並辨認：

$$k_i = \begin{cases} K & \text{if } s_{i-1}(v) \neq 0 \wedge s_{i-1}(x, y) = s_i(x, y), \\ 0 & \text{other.} \end{cases} \quad (6)$$

觀察車輛時間序列訊息中當前與前一刻的資訊，若前一刻的速度訊息不等於 0、仍處移動狀態，但是當前位置訊息卻相同於前一刻的位置訊息，則將其車

輛移動軌跡標記為 K 值，否則設為 0。將透過此方法標記的序列以第 12 項特徵輸入分類器判斷 EventualStop 異常行為，提升模型分辨的準確度。

4 結果與討論

4.1 資料集與 MDS 重建

本研究將會重現研究 [24] 所提出之整合性車輛異常行為檢測系統，以此系統架構為核心對當中的分類器進行超參數最佳化，並利用 VeReMi Extension 資料集 [11] 實施模型的訓練與評估驗證。

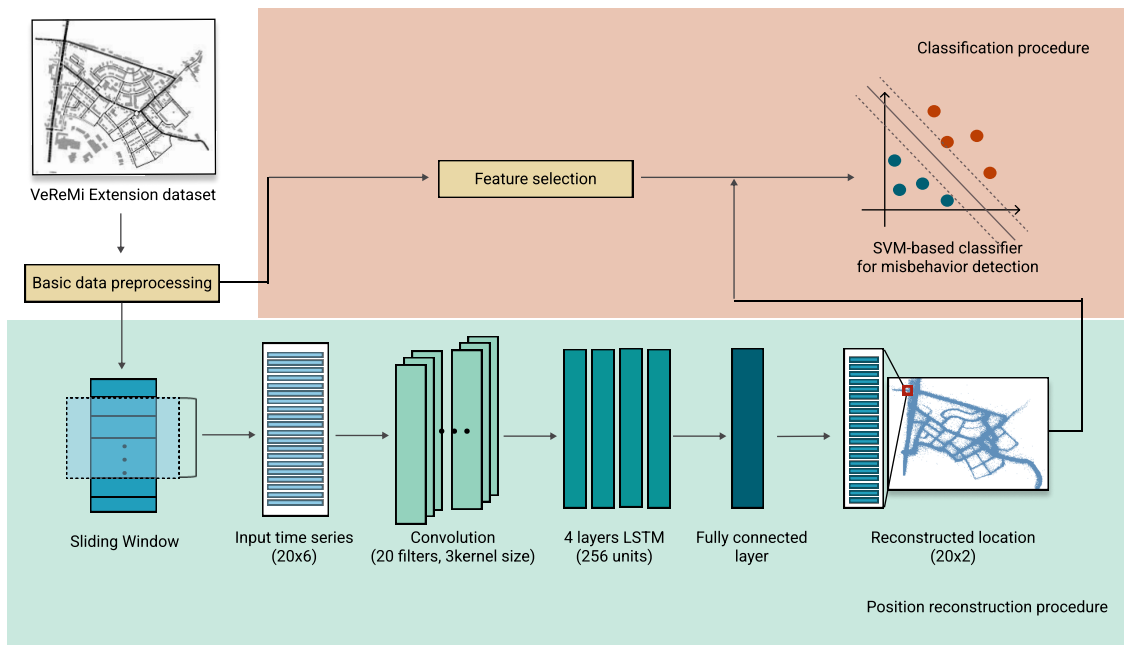


圖 2: 車載 MDS 架構

圖2所示是 Cheng 等人 [24] 發表的車載 MDS 架構，主要建構流程大致可分作位置重構及分類兩個階段。在位置重構階段目的是將輸入的時間序列資料，以標準行為模式預測下一時段的位置，比較原資料位置與預測資料位置間的差距，初步判斷是否為異常車輛行為。此階段由 CNN-LSTM 生成重構的位置，模型以資料集中的 BSM 構成的時間序列為輸入，將 BSM 中車輛的 x、y 軸上的位置、速度及加速度組成一組向量並依據時間排序，利用大小設定為 10 的滑動窗口拿取資料，建立以 20 個向量為單位的時間序列，每個時間序列的 20 組向量會與前一個時間序列有 10 組的重疊，即第一序列由時間上

前 20 組訊息組成、第二組由第 10 至第 30 組的訊息組成，以此類推。又因 CNN-LSTM 需學習正常車輛的行為模式，以利後續預測，在模型訓練階段會以正常行為資料構成的時間序列進行訓練，當以異常行為資料構成的時間序列輸入訓練好的模型，模型預測的位置可能與原資料產生較大落差，此差值則作為下一階段的輸入特徵之一使用。階段成果如圖3，經過 CNN-LSTM 以正常模式進行位置重構後，正常車輛基本上都還是落在道路附近，但是異常車輛位置預測過後就會將速度、加速度等等的異常體現於位置上，導致其重構的位置明顯被打散，多數異常行為車輛便散落於道路之外。

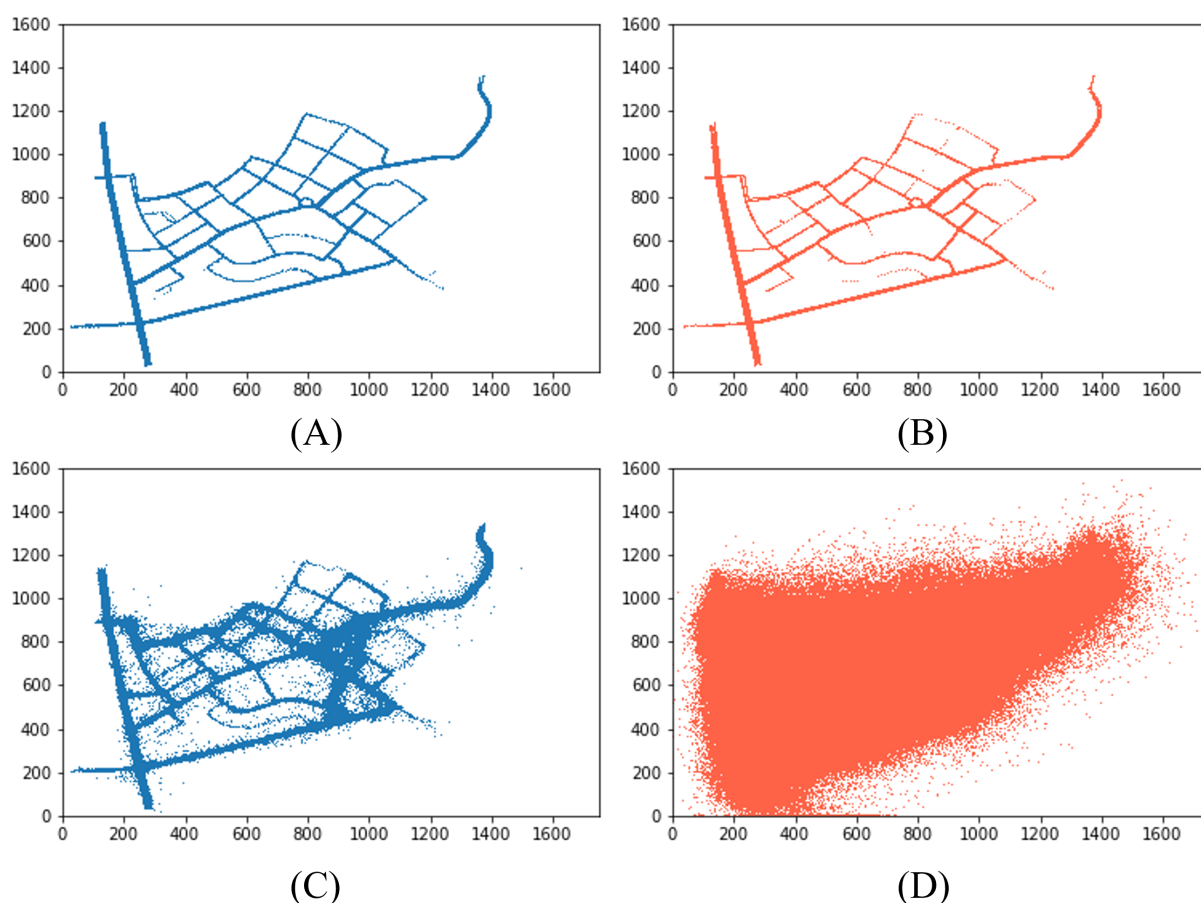


圖 3: (A) 正常行為車輛的原始位置； (B) 異常行為車輛的原始位置；
(C) 正常行為車輛的重構位置； (D) 異常行為車輛的重構位置

分類階段中的輸入特徵除了包括上一階段的位置重構特徵，也包含下表2其他 10 項特徵：

表 2: SVM 分類器於本研究之 11 項輸入特徵

| | 特徵 | 說明 |
|----|---------|-----------------------|
| 1 | 重構行為偏差 | 車輛行為與標準模式間的偏差 |
| 2 | 位置合理性檢查 | 以位移方程式測試位移區間合理性 |
| 3 | 速度計算資訊 | 以 x 軸總位移和時間計算 x 軸平均速度 |
| 4 | 速度計算資訊 | 以 x 軸速度和時間預測 x 軸平均速度 |
| 5 | 速度計算資訊 | 特徵 3 與特徵 4 的差異 |
| 6 | 速度計算資訊 | 以 y 軸總位移和時間計算 y 軸平均速度 |
| 7 | 速度計算資訊 | 以 y 軸速度和時間預測 y 軸平均速度 |
| 8 | 速度計算資訊 | 特徵 6 與特徵 7 的差異 |
| 9 | 距離計算資訊 | 透過兩個 BSM 間位移計算距離總和 |
| 10 | 距離計算資訊 | 以平均速度預測總位移 |
| 11 | 距離計算資訊 | 特徵 9 與特徵 10 的差異 |

特徵 1 是由平均絕對誤差 (mean absolute error, MAE) 式 7 計算原始位置 p_x, p_y 與通過 CNN-LSTM 模型重構後的位置 p'_x, p'_y 之間的差異。

$$\text{MAE} = \frac{|p_x - p'_x| + |p_y - p'_y|}{2} \quad (7)$$

特徵 2 表示一段時間內車輛位置的合理性，主要透過式 8 評估，具體會透過在兩 BSM 發送間隔時間 t 內，速度 v_{i-1} 以及加速度的信賴區間 a 計算可能的預測位移區間，並比較直接使用原始資料中 BSM 的時間戳與位置取得時間內的位移差異，以判斷序列的真實性，此特徵的數值越大代表具有較低的可信度，表示是異常行為的可能性較高。

$$\Delta x = x_i - x_{i-1} = v_{i-1} t + \frac{1}{2} a t^2 \quad (8)$$

特徵 3~8 分別對 x、y 軸方向使用不同的公式計算一段時間的平均速度，並提取差值作為特徵之一。式 9 以總位移除以總時間計算，式 10 則假設車輛在每段時間間距皆等速運動，則可依式子算出預測總位移，其中 n 表示的是序列中的 BSM 數量。

$$\bar{v} = \frac{x_n - x_0}{t_n - t_0} \quad (9)$$

$$v_{\text{predicted}} = \frac{\sum_0^n (v_{i-1}t)}{t_n - t_0} \quad (10)$$

特徵 9、10 是以不同的公式計算的總位移。特徵 9 是透過每兩個 BSM 中所提供的位置，計算出的距離總和，公式如 11；特徵 10 分別將 x 及 y 軸方向的速度加總計算速度平均值 \bar{v} ，再與總時間相乘計算總距離。特徵 11 則是由特徵 9、10 之間的差值計算而來。

$$D = \sum_i^n \sqrt{(x_i - x_{i-1})^2 + (y_i - y_{i-1})^2} \quad (11)$$

$$D' = \bar{v}(t_n - t_0) \quad (12)$$

綜合以上方法提取的特徵，將會在分類階段輸入至 SVM 分類器以分辨車輛是否存在異常行為。整體而言資料集將分批用於以上兩階段，在位置重構階段採用 90% 的正常行為數據進行訓練以習得標準車輛行為模式，而剩餘的正常以及 19 種異常行為數據則取 70% 用於各異常行為 SVM 分類器的訓練，其餘 30% 則做為測試集，為 19 種不同異常行為的分辨成效進行評估。

4.2 實驗設定與分析

本研究提出了在系統分類階段以 DE 對模型實施超參數最佳化、增加以 EventualStop 行為模式啟發的特徵，對於這兩項提升判斷準確度的方法，設計三個實驗以橫向比對論證方法的有效性。實驗一比較重建的原系統與經 HPO 的系統間，對於異常行為判斷準確度的差異，以驗證本研究使用的 HPO 方法應用在 MDS 系統為有效；實驗二額外新增三種不同的分類器，比較以預設超參數值與經 HPO 後效能上的差異，觀察以 DE 實行的超參數最佳化方法在不同分類器上的適用性；實驗三則是比較增加基於 EventualStop 特徵前後，對於 MDS 在異常行為分辨上的影響性，決定特徵的加入是否有利異常行為的判別。

A. 實驗一 使用 SVM 分類並進行超參數最佳化

實驗一以重建的 MDS 作為對照組，比較將其中 SVM 分類器以 DE 實行超參數最佳化的效力，對於其中相關參數的設定如表3。由於選定使用 RBF kernel，DE 僅需對於 SVM 分類器當中懲罰參數 C 及核函數參數 γ 設定範圍並進行調整，種群初始規模 $n_{||p||}$ 則考量到此情境下的搜索域範圍而隨之相對設定較小。依據以上設定，DE 在初始化階段會隨機在 C 及 γ 範圍的上界與下界中，隨機產生 7 個組合當作本次最佳化的初始種群，並於突變階段在 DE 的控制參數之一的突變權重 F 影響下，以選定的突變策略產生種群之外的組合，並且此處 F 將隨著迭代的進程進行動態變化，依 SA 的降溫模式不斷的縮小，使突變方向能夠由最初的保持開放隨機探索，到後期的加快朝向當前最佳解收攏，在交配階段參考雜交概率 c_r 決定新子代之於父代差異性，在終止條件上則是設定最多實施 200 次的迭代，倘若在 200 次之內的連續數代皆停滯於同一適應值、難以見其發展性，即提早終止運算並釋出當前的最佳解作為該次試驗的最佳超參數組合，並以測試集對其進行評價。

表 3: 參數設定

| | | | |
|-------------|-------|----------------|----------|
| C | 0.5~2 | γ | 0.01~0.5 |
| $n_{ p }$ | 7 | F | 0.8 |
| c_r | 0.75 | max_generation | 200 |

圖4為實驗一結果，可以見得在 19 種異常行為上實驗組與對照組之差異，雖然對照組的原系統在某些異常行為的判定已有接近 100% 準確度的表現，然而實驗組的系統在經 DE 實施超參數最佳化後，能夠看到在像是 EventualStop、ConstPosOffset 的異常行為類別上，有相對明顯的提升，尤其 ConstPosOffset 以 2.4% 居最高的提升度平均。此外若分別以準確度 (Accuracy)、精確度 (Precision)、召回率 (Recall) 及 F1-score 四項評估指標評價的數據表現，綜合所有異常行為的平均值皆有 0.3%~0.7% 成長，驗證 MDS 系統確實透過 HPO

在異常行為的判別上全方位獲得成長。




圖 4: SVM 分類器經超參數最佳化於 19 種異常行為分辨成效

B. 實驗二 使用 DE 進行其他分類器之超參數最佳化

實驗二新增除原系統 SVM 外的三種不同的分類器，分別為 KNN、Decision tree、XGBoost，比較以預設超參數值與經 HPO 後效能上的差異，觀察 DE 演算法在 HPO 問題上面對不同分類器應用上的適應程度。下表4列出三個分類器個別可供調整的超參數：

表 4: KNN、Decision tree、XGBoost 可調整之超參數

| classifier | hyperparameter |
|---------------|---|
| KNN | n_neighbors, p, weights |
| Decision Tree | criterion, splitter, max_depth, class_weight, min_samples_split, min_samples_leaf, max_features |
| XGBoost | objective, eval_metric, max_depth, eta, min_child_weight, gamma, subsample, colsample_bytree |

由上表中可知，KNN 可以透過調整參考的近鄰數量、運用不同距離計算方式及距離權重將分類器模型調整至最佳化狀態；Decision tree 的超參數最佳化主要考量的是適宜的樹深以及最佳的節點與分支，以重要參數 criterion 切換不同

不純度評估指標以利尋找最佳節點與分枝，超參數 `max_depth` 控制最大深度，超過部分進行剪枝的操作，並透過 `max_features`、`min_samples_split` 等調和各種分枝時考量的特徵數與訓練樣本數，以多樣的超參數的共同調控決策樹的長成；XGBoost 方面，本研究主要選用 `gbtree booster`，並調整此 `booster` 的相關控制超參數，像是以 `eta` 調整修改分類的權重幅度、`gamma` 決定損失函數 `objective` 的下降幅度、或是以 `max_depth` 以及 `min_child_weight` 相關超參數對於 `tree booster` 進行調控，並利用 `eval_metric` 決定評估指標的類型以最佳化模型。實驗中分別比較 KNN、Decision tree、XGBoost 設定預設值的超參數，與經過 HPO 過程的模型在異常行為辨認上的差異性，由此作為本研究之方法對於不同分類器適用性的比較基準。




圖 5: SVM、KNN、Decision tree、XGBoost
經超參數最佳化於 19 種異常行為分辨成效比較-1




圖 6: SVM、KNN、Decision tree、XGBoost
經超參數最佳化於 19 種異常行為分辨成效比較-2

圖5、6為實驗二成果，圖中上方的深色區塊指代的是相較最佳化前，利用 HPO 調整能夠達到的平均提升率。在使用預設超參數的狀態下，SVM 相

比於 KNN、Decision tree、XGBoost 在 19 種異常行為分辨的平均上，獲更高的判斷度準確度。而不同分類器經超參數最佳化後，在原先判別效能較低落的異常行為種類 ConstPost、DelayedMessages、DOS 等都有不菲的提升，像是 KNN 最高在 ConstPost 這項異常行為的分辨度提升了 4.2%，而 XGBoost 最高在 DatareplaySybil 的分辨準確度提升 4.1%，Decision tree 則是在異常行為 DelayedMessages 上獲最高的 13% 準確率提升。整體而言每個分類器相對於預設情況，經最佳化後的分類器在異常行為的分辨上皆有成長，並以 KNN 以 19 種異常行為平均上升 0.56% 的分辨率為四種異常行為中的第一，在 F1-score 的評估也有 0.65% 的提升，以整體數據而言似是提升不多，主因是不少異常行為原始辨別率高，提升空間有限，部分提升率較多的數值則是受 19 個種類平均中和，所以以整體平均數據而論較難以彰顯最佳化的提升成果。總體而論綜合實驗結果，本研究運用之方法對於四種分類器在該車載異常行為檢測系統的應用情境上，皆能使其有效提升。

C. 實驗三 使用新特徵並進行超參數最佳化

實驗三以未新增基於 EventualStop 特徵的 MDS 作為對照，實驗比對新增特徵前後對於各個異常行為分辨率差異。




圖 7: 基於 EventualStop 特徵於 19 種異常行為分辨成效

圖7為實驗三結果，觀察圖中結果可知，新增的異常行為對於 EventualStop、DoS、ConstPost 三項異常行為上的辨認上較有助益，最高幫助 DoS 類別在準確率 (Accuracy) 上提升 3.2%，並且數據顯示在精確度 (Precision) 方面的上升最為顯著，平均在異常行為 DoS 上提升 4.2%、EventualStop 在精確度的平均上則提升 3.5%，可分析此新增特徵透過協助減少正常行為遭誤判為異常的情況，輔助系統提升整體的分辨能力。

5 結論與未來工作

本研究由使用 DE 演算法針對車輛異常行為檢測系統進行超參數最佳化、以及增加由 EventualStop 的異常行為模式啟發產生的新特徵，由兩方面著手提升系統的判斷能力。研究大致分成三項實驗，橫向比較並論證本文提出的研究為有效。實驗一以重建的 MDS [24] 為對照組，比對經 DE 演算法實施 HPO 的 MDS，在 19 種異常行為的辨認上的效能。實驗結果指出，經超參數最佳化的 MDS 在原判別率較低的異常行為種類，最多能夠提升平均 2.4% 的準確度，驗證本研究所使用的 HPO 方法確實能夠為異常行為檢測系統判斷準確度帶來有效提升。在驗證此方法對於原系統 SVM 分類器的有效性後，實驗二則是額外增加 KNN、Decision tree 及 XGBoost 三個種類的分類器，觀測實驗以 DE 演算法分別進行超參數最佳化，與使用預設超參數值訓練的對照組之間分辨能力的差異，由實驗結果可知 KNN 平均提升度最顯著，而對於其餘分類器也都有不同程度的有效提升。實驗三則主要比對增加以 EventualStop 的異常行為模式啟發產生的新特徵，對於 MDS 在判別不同異常行為上的影響力，實驗結果表明在 EventualStop、DoS、ConstPost 三項異常行為上有較顯著提升，也驗證加入新特徵的舉措對於 MDS 判斷力的提升具有有效性。整體實驗結果說明本文中以 DE 實施超參數最佳化，以及增加基於 EventualStop 的異常行為模式啟發的第 12 項特徵，能夠使車輛異常行為檢測系統達到平均 97.6% 的分辨準確率。

6 致謝

研究由科技部大專學生研究計畫補助，計畫編號 MOST 111-2813-C-110-031-E、計畫編號 MOST108-2221-E-005-021-MY3，特此致謝。此外本研究投稿於第 17 屆無線、隨意及感測網路研討會 [25]，在此也感謝大會頒予最佳論文獎之殊榮。

參考文獻

- [1] W. H. Organization, “Global status report on road safety 2018,” 2018. [Online]. Available: <https://www.who.int/publications/i/item/9789241565684>
- [2] I. T. Forum, “Zero road deaths and serious injuries,” 2016. [Online]. Available: <https://www.oecd-ilibrary.org/content/publication/9789282108055-en>
- [3] A. Sharma, R. Chaki, and U. Bhattacharya, “Applications of wireless sensor network in intelligent traffic system: A review,” in *3rd International Conference on Electronics Computer Technology*, vol. 5, 2011, pp. 53–57.
- [4] B. Xiao, B. Yu, and C. Gao, “Detection and localization of sybil nodes in VANETs,” in *Proceedings of the 2006 workshop on Dependability issues in wireless ad hoc networks and sensor networks*, 2006, pp. 1–8.
- [5] B. E. Roy Sumner and J. Baker, “SAE J2735 standard: Applying the systems engineering process,” 2013. [Online]. Available: <https://rosap.ntl.bts.gov/view/dot/3413>
- [6] X. He, K. Zhao, and X. Chu, “AutoML: A survey of the state-of-the-art,” *Knowledge-Based Systems*, vol. 212, p. 106622, 2021.
- [7] V. Belenko, V. Krundyshev, and M. Kalinin, “Synthetic datasets generation for intrusion detection in VANET,” in *Proceedings of the 11th International Conference on Security of Information and Networks*, 2018, pp. 1–6.
- [8] R. W. Heijden, T. Lukaseder, and F. Kargl, “VeReMi: A dataset for comparable evaluation of misbehavior detection in VANETs,” in *Proceedings of the International Conference on Security and Privacy in Communication Systems*, 2018, pp. 318–337.
- [9] L. Codecá, R. Frank, S. Faye, and T. Engel, “Luxembourg SUMO traffic (LuST) scenario: Traffic demand evaluation,” *IEEE Intelligent Transportation Systems Magazine*, vol. 9, no. 2, pp. 52–63, 2017.
- [10] C. Sommer, R. German, and F. Dressler, “Bidirectionally coupled network and road traffic simulation for improved IVC analysis,” *IEEE Transactions on Mobile Computing*, vol. 10, no. 1, pp. 3–15, 2010.
- [11] J. Kamel, M. Wolf, R. W. van der Hei, A. Kaiser, P. Urien, and F. Kargl, “VeReMi extension: A dataset for comparable evaluation of misbehavior detection in VANETs,” in *Proceedings of the ICC 2020-2020 IEEE International Conference on Communications*, 2020, pp. 1–6.

- [12] J. Grover, V. Laxmi, and M. S. Gaur, “Misbehavior detection based on ensemble learning in VANETs,” in *Proceedings of the International Conference on Advanced Computing, Networking and Security*, 2011, pp. 602–611.
- [13] S.-Y. Wang and C. Chou, “NCTUns 5.0 network simulator for advanced wireless vehicular network researches,” in *Proceedings of the 2009 Tenth International Conference on Mobile Data Management: Systems, Services and Middleware*, 2009, pp. 375–376.
- [14] S. So, P. Sharma, and J. Petit, “Integrating plausibility checks and machine learning for misbehavior detection in VANET,” in *Proceedings of the 2018 17th IEEE International Conference on Machine Learning and Applications*, 2018, pp. 564–571.
- [15] T. Alladi, A. Agrawal, B. Gera, V. Chamola, B. Sikdar, and M. Guizani, “Deep neural networks for securing IoT enabled vehicular ad-hoc networks,” in *Proceedings of the ICC 2021-IEEE International Conference on Communications*, 2021, pp. 1–6.
- [16] H. Grover, T. Alladi, V. Chamola, D. Singh, and K.-K. R. Choo, “Edge computing and deep learning enabled secure multitier network for internet of vehicles,” *IEEE Internet of Things Journal*, vol. 8, no. 19, pp. 14 787–14 796, 2021.
- [17] G. Luo, “A review of automatic selection methods for machine learning algorithms and hyper-parameter values,” *Network Modeling Analysis in Health Informatics and Bioinformatics*, vol. 5, no. 1, pp. 1–16, 2016.
- [18] L. Yang and A. Shami, “On hyperparameter optimization of machine learning algorithms: Theory and practice,” *Neurocomputing*, vol. 415, pp. 295–316, 2020.
- [19] M. Injadat, A. Moubayed, A. B. Nassif, and A. Shami, “Systematic ensemble model selection approach for educational data mining,” *Knowledge-Based Systems*, vol. 200, p. 105992, 2020.
- [20] J. Bergstra and Y. Bengio, “Random search for hyper-parameter optimization,” *Journal of Machine Learning Research*, vol. 13, 2012.
- [21] J. Snoek, H. Larochelle, and R. P. Adams, “Practical bayesian optimization of machine learning algorithms,” *Advances in Neural Information Processing Systems*, vol. 25, no. 2, 2012.
- [22] A. Gogna and A. Tayal, “Metaheuristics: Review and application,” *Journal of Experimental & Theoretical Artificial Intelligence*, vol. 25, no. 4, pp. 503–526, 2013.

- [23] M. Schmidt, S. Safarani, J. Gastinger, T. Jacobs, S. Nicolas, and A. Schülke, “On the performance of differential evolution for hyperparameter tuning,” in *Proceedings of the 2019 International Joint Conference on Neural Networks*, 2019, pp. 1–8.
- [24] H.-Y. Hsu, N.-H. Cheng, and C.-W. Tsai, “A deep learning-based integrated algorithm for misbehavior detection system in VANETs,” in *Proceedings of the 2021 ACM International Conference on Intelligent Computing and its Emerging Applications*, 2021, pp. 53–58.
- [25] Y.-Q. Lee, S.-H. Chiu, J.-L. Tung, and C.-W. Tsai, “A misbehavior detection system based on differential evolution algorithm,” in *Proceedings of the 17th Workshop on Wireless, Ad-Hoc and Sensor Networks*, 2022.